

AI 自动化运营基础设施 架构白皮书

V9 正式版 | Agentic RAG 与多层 Agent 架构

面向内容生成、自动发布、AI 客服、数据反馈与持续优化的一体化运营基础设施设计。

01	执行摘要
02	系统总体架构
03	核心架构思想
04	中央 AI 智能体层
05	Agentic RAG 智能检索层
06	AI 中央控制层
07	AI 内容与视频生成体系
08	调度与队列系统
09	分布式执行层
10	中央 Agent 与 OpenClaw 的边界
11	AI 客服体系
12	风控体系
13	数据反馈与持续优化闭环
14	故障恢复体系
15	部署结构与系统生命周期

本系统定位为面向多平台内容运营场景的 AI

自动化运营基础设施。系统目标不是单点脚本自动化，而是建立覆盖内容生成、智能调度、分布式执行、AI 客服、数据反馈与持续优化的完整运营闭环。

AI 内容生成

自动生成标题、文案、标签、SEO 内容与 CTA。

智能 workflow 编排

通过中央 Agent 与 OpenClaw 分层管理任务。

分布式自动执行

Mac Worker 集群负责平台交互与发布执行。

AI 客服

处理评论、私信、FAQ 与人工接管。

数据反馈分析

采集 CTR、转化率、评论率等指标。

持续优化

基于数据回流优化 Prompt、选题与发布策略。

系统最终目标

形成“内容生成 - 自动发布 - 数据反馈 - 优化分析 - 下一轮生成”的持续自迭代运营闭环。

系统整体采用分层架构，中央侧负责智能决策、知识检索、模型推理与调度；执行侧负责浏览器自动化、账号会话与平台交互；平台数据最终回流至数据库与知识库，用于持续优化。

中央 AI 智能体层

内容生成 Agent / 数据分析 Agent / 调度 Agent / 风控 Agent / 客服 Agent / 优化 Agent

Agentic RAG 智能检索层

Qdrant / PostgreSQL / Embedding / 历史数据 / FAQ / 业务资料

AI 中央控制层

Llama / FastAPI / Scheduler / Redis / ComfyUI

分布式执行层

OpenClaw / Playwright / Chrome Profiles / Proxy / Mac Worker

平台交互层

TikTok / X / Instagram / YouTube

数据反馈层

CTR / 播放量 / 评论率 / 转化率 / Prompt 优化 / 知识库更新

图 1：AI 自动化运营基础设施总体拓扑。

系统采用 “ 中央智能决策 + 分布式执行节点 ” 的架构模式。中央智能体负责分析与决策，执行节点负责真实平台操作，两者通过 Scheduler 与 Redis Queue 解耦。

设计原则	说明
中央智能控制	AI 推理、知识检索、任务调度、数据分析集中在服务器侧完成。
分布式执行	Mac Worker 作为执行节点，负责平台交互和浏览器自动化。
Agentic RAG	检索不再是固定前置步骤，而由 Agent 根据任务动态选择数据源与检索策略。
职责隔离	中央 Agent 负责决策，OpenClaw 负责执行编排，Playwright 负责浏览器操作。
数据驱动优化	平台表现数据回流后参与 Prompt、选题、发布时间与客服策略优化。

中央 AI 智能体层运行在 Windows AI Server，属于系统高层决策中心。其任务是理解目标、分析数据、制定策略，并输出可执行任务，而不是直接操作平台。

内容生成 Agent

生成标题、文案、标签、SEO 内容与 CTA。

数据分析 Agent

分析 CTR、转化率、发布时间和用户行为。

调度 Agent

制定发布时间、账号选择和平台分发策略。

风控 Agent

评估账号风险、平台限制和异常行为。

AI 客服 Agent

处理评论、私信、FAQ、情绪识别与人工接管。


优化 Agent

基于数据复盘优化 Prompt、选题与内容结构。

定位说明

中央 Agent 负责“思考、分析、规划、决策、优化”。它不直接执行浏览器动作，也不直接承担平台发布。

系统采用 Agentic RAG，而非传统固定式 RAG。传统 RAG 通常是“检索 - 拼接 - 生成”的线性流程；Agentic RAG 会先理解任务，再判断需要访问哪些数据源，并通过多轮检索、推理与校验构建上下文。



知识类型	主要内容
产品资料	产品文档、售后规则、物流政策、退款规则。
内容资料	历史爆款、高 CTR 文案、标签、标题结构。
数据资料	CTR、转化率、发布时间、观看时长、互动率。
客服资料	FAQ、客诉记录、历史对话、高转化回复模板。
执行资料	账号状态、代理状态、历史风控与失败记录。

AI 中央控制层负责模型推理、任务生命周期、调度、队列管理、状态同步、视频生成、日志记录与数据持久化。

模块	职责
Llama	内容生成、客服回复、数据解释与策略建议。
FastAPI	中央 API 服务，统一接收任务与管理内部调用。
Scheduler	任务调度、账号分配、冷却、限流与重试策略。
Redis	任务队列、分布式锁、心跳检测与状态同步。
PostgreSQL	任务、账号、发布记录、客服记录与指标数据存储。
Qdrant	向量知识库与语义检索。
ComfyUI	视频生成 Workflow 执行。

关键原则


AI 中央控制层负责生成决策与任务编排，不直接操作平台账号；平台交互由分布式执行层完成。

07

AI 内容与视频生成体系

内容生成由中央 Agent 与 Agentic RAG 共同完成，视频生成由视频生成 Agent 选择 ComfyUI Workflow 后执行。

流程	步骤
文案生成	Scheduler 创建任务 - 内容生成 Agent 分析目标 - Agentic RAG 检索历史数据 - 构建 Prompt - Llama 推理 - 写入 PostgreSQL。
视频生成	FastAPI 接收任务 - 视频生成 Agent 选择 Workflow - 调用 ComfyUI API - 输出视频 - 登记数据库。
输出资产	标题、描述、标签、SEO 内容、CTA 文案、评论区引导、短视频文件。



Scheduler 是任务调度中心，负责发布时间管理、账号分配、代理分配、风控控制、冷却控制、自动重试与优先级管理。Redis Queue 负责连接中央控制层与分布式执行层。

任务状态	含义
pending	任务已创建，等待调度。
locked	任务已被锁定，防止重复执行。
running	任务正在执行。
success	任务执行成功。
failed	任务执行失败。
retry	任务进入重试流程。
dead	超过恢复条件，进入死信队列。

Scheduler 创建任务



写入 Redis Queue



Mac Worker 获取任务



OpenClaw 编排执行



Playwright 执行发布



结果同步回服务器

分布式执行层采用 Mac Worker 集群。每个执行节点通过 OpenClaw 进行 workflow 编排，通过 Playwright 完成浏览器自动化，通过 Chrome Profiles 和代理系统实现账号与会话隔离。

模块	职责
OpenClaw	执行侧 workflow 编排、异常恢复、状态同步、重试策略。
Playwright	浏览器启动、会话加载、视频上传、内容填写、发布执行。
Chrome Profiles	平台账号会话隔离，保存登录状态与 Cookie。
Proxy System	IP 隔离与账号代理绑定。
Worker Manager	节点心跳、任务状态与执行结果同步。

10


中央 Agent 与 OpenClaw 的边界

服务器上的中央 Agent 与 OpenClaw 的 Agent 不是同一层级。中央 Agent 属于智能决策层，OpenClaw 属于执行编排层。明确边界可以避免把业务决策下沉到执行节点，从而降低复杂度与维护风险。

对比项	中央 AI Agent	OpenClaw Agent
运行位置	Windows AI Server	Mac Worker
核心职责	分析、规划、决策、优化	执行、编排、恢复、状态同步
关注对象	业务策略、数据、知识、风险	浏览器、页面、Profile、发布流程
典型任务	决定发什么、何时发、用哪个账号、是否转人工	打开页面、上传视频、填写内容、处理异常



AI 客服体系用于处理评论、私信、FAQ、用户咨询与人工接管分流。客服 Agent 会结合 Agentic RAG 检索 FAQ、售后规则、历史客服记录与用户上下文，再生成回复或触发人工接管。



必须转人工场景	说明
退款纠纷	涉及资金、订单争议或规则边界。
法律投诉	涉及法律、合规或平台政策风险。
高风险客诉	可能引发舆情或平台处罚。
连续负面情绪	用户多轮表达强烈不满。
多轮无法解决	AI 无法在限定轮次内完成问题解决。

12

风控体系

风控体系的目标是维持低频率、拟人化、可恢复的账号行为，降低多账号关联、异常登录、平台风控与 Shadowban 风险。

模块	作用
限流系统	控制发布、评论、私信等行为频率。
冷却系统	防止连续行为造成平台异常判断。
Shadowban 检测	识别流量异常、曝光异常与互动异常。
IP 隔离	代理与账号固定绑定，降低关联风险。
会话隔离	不同账号使用独立 Profile 与 Cookie。
指纹管理	控制浏览器指纹、设备信息与行为特征。

风控原则


系统行为应保持低频率、分散化、拟人化，并具备异常检测、冷却、降级与人工接管能力。

13

数据反馈与持续优化闭环


数据反馈层持续采集平台表现数据，并将结果写入 PostgreSQL 与 Qdrant。数据不仅用于报表展示，也用于下一轮内容生成、客服优化、发布时间优化与选题策略优化。

指标	用途
CTR	评估标题、封面与内容切入点。
播放量	评估内容曝光与平台推荐情况。
互动率	评估内容吸引力与用户参与度。
评论率	评估话题讨论度与客服触发频率。
转化率	评估商业效果与 CTA 有效性。
观看时长	评估视频结构与内容节奏。



系统必须支持 Worker 恢复、队列恢复、GPU OOM

恢复、自动重试、死信队列、会话恢复与状态同步。故障恢复体系是系统长期稳定运行的基础。



故障类型	恢复策略
Worker 掉线	心跳检测后释放锁，并转移任务。
队列堵塞	检查锁状态、重试队列和死信队列。
GPU OOM	终止当前推理或渲染任务，释放显存并重试。
会话失效	进入重新登录或人工接管流程。
发布失败	保存截图与错误原因，进入重试或死信队列。

部署节点	核心模块
Windows AI Server	Llama、Embedding、Qdrant、FastAPI、Scheduler、Redis、PostgreSQL、ComfyUI、中央 AI Agents。
分布式 Mac Worker 集群	OpenClaw、Playwright、Chrome Profiles、Proxy System、Session Persistence。

